

目录

第一章 绪论	7
1.1 研究背景	7
1.1.1 稀疏观测下的时空场重建需求	7
1.1.2 科学机器学习与算子学习的推动作用	7
1.2 研究动机与应用场景	8
1.3 研究问题定义与数学形式化	8
1.3.1 观测模型与重建目标	8
1.3.2 任务口径：超分辨与裁剪（示例）	9
1.4 稀疏观测重建的关键挑战	9
1.4.1 混叠与频谱失真	9
1.4.2 训练口径与评测口径断裂	9
1.4.3 非周期边界与局部伪影扩散	9
1.4.4 可复现性与可审计性	9
1.5 相关工作综述与定位（聚焦可落地引用）	10
1.5.1 物理约束学习：PINN	10
1.5.2 算子学习：FNO 与 DeepONet	10
1.5.3 物理信息与算子学习的结合：Physics-informed DeepONet	10
1.5.4 本文定位	10
1.6 研究内容与技术路线	11
1.6.1 总体路线	11
1.6.2 指标体系与一致性目标	11
1.6.3 损失设计（示意）	11
1.7 创新点与主要贡献（面向论文审查口径）	12
1.8 论文结构安排	12
1.9 研究伦理与合规	12
1.10 本章小结	13
1.11 关键术语表（本章使用口径）	13

第二章 相关工作	15
2.1 引言	15
2.2 问题范式与两类核心路线：PINN 与算子学习	16
2.2.1 PINN：以物理残差为关键的约束学习	16
2.2.2 算子学习：从“拟合单个解”转向“学习解算子”	16
2.2.3 DeepONet：算子近似的分支—主干结构	17
2.3 稀疏观测与退化建模：观测算子、抗混叠与口径一致性	17
2.3.1 稀疏观测的“信息瓶颈”与退化算子表述	17
2.3.2 抗混叠（anti-aliasing）在下采样口径中的必要性	17
2.3.3 口径一致性（ H 与 DC ）与可复现评测	18
2.4 时空耦合建模与训练偏置：多尺度、频谱偏置与因果性	18
2.4.1 时空结构的多尺度性与频谱偏置问题	18
2.4.2 因果性与时序稳定性：从 PINN 到算子序列建模	18
2.4.3 与稀疏观测重建的关系	19
2.5 离散化误差与别名（aliasing）：跨网格鲁棒性的关键障碍	19
2.6 基准与数据：PDEBench 的意义与边界	20
2.7 统计检验与工程成本：从“论文结果”走向“可部署结论”	20
2.7.1 多种子统计与效应量	20
2.7.2 资源成本透明化	20
2.8 文献关系框架与对照维度（可直接用于论文配图/配表）	21
2.8.1 “方法—理论—基准—问题”四象限关系框架（文字版）	21
2.8.2 关键方法对照表（面向稀疏观测重建的评审维度）	21
2.9 符号与记号对齐（与第 3 章接口，避免跨章歧义）	21
2.10 本章小结与章节过渡	22
第三章 方法	23
3.1 问题定义与数学形式化	23
3.2 统一观测算子 H ：抗混叠与口径声明	24
3.2.1 SR 观测口径（下采样）	24
3.2.2 Crop 观测口径（裁剪）	24
3.3 H/DC 单一口径复用：硬约束与阻断式审计	24
3.3.1 硬约束：训练退化 $DC \equiv H$	24
3.3.2 阻断式等价性检验（不通过则不进入统计）	24
3.4 模型接口：统一输入打包与可替换算子层	25
3.4.1 统一输入打包（接口契约）	25
3.4.2 算子学习视角（方法定位）	25
3.5 三件套损失：重建、低频谱一致性、原值域观测一致性	25
3.5.1 标准化域与原值域	25

3.5.2	重建损失 L_{rec}	25
3.5.3	低频谱一致性损失 L_{spec}	25
3.5.4	原值域观测一致性损失 L_{dc}	26
3.5.5	总损失	26
3.6	复现闭环：配置快照、环境指纹与一致性归档	26
3.7	研究设计：对照、消融与敏感性分析	26
3.8	统计检验：显著性与效应量	26
3.9	与 PINN 物理残差约束的关系（边界定位）	26
第四章	实验设置	29
4.0	引言	29
4.1	预备定义：函数空间、算子范数与误差度量	29
4.2	观测口径一致性（ H/DC 复用）的可证明意义	30
4.2.1	命题 4.1：评测口径误差由重建误差上界控制（前提：同一 H ）	30
4.2.2	SR 与 Crop 两类 H 的算子稳定性：为何 $\ H\ _{\text{op}}$ 往往温和	30
4.2.3	欠定性与必要补充：为何仅 L_{dc} 不够	31
4.3	三件套损失的理论作用分解：从可行到可泛化、可解释	31
4.3.1	L_{rec} ：逼近误差的直接控制项	31
4.3.2	L_{dc} ：把优化目标绑定到评测口径上	31
4.3.3	L_{spec} ：低频结构优先与谱偏置缓解	32
4.4	收敛性与训练稳定性：为何需要课程学习与因果/时序约束	32
4.4.1	PINN 的失败模式与 NTK 视角	32
4.4.2	因果性训练与先易后难的合理性	32
4.5	神经算子泛化与跨网格鲁棒性：为何算子视角更匹配 PDE 数据	33
4.6	离散化与混叠：为何必须把抗混叠口径写进方法	33
4.6.1	混叠的结构性风险	33
4.6.2	别名无关学习与跨网格一致性	33
4.7	解码稳定性：为何坚持“上采样 + 小卷积”而非反卷积堆叠	33
4.8	确定性训练与可复现性：把可复现当作理论假设的一部分	34
4.9	理论命题到实证设计的映射	34
4.10	小结	34
第五章	结果与分析	37
5.1	本章概述	37
5.2	内容（占位）	37
第六章	讨论	39
6.1	实验设置	39

6.1.1	数据集与数据治理	39
6.1.2	固定切分与逐通道标准化	39
6.1.3	观测生成与口径一致性 (H/DC 同源复用)	39
6.1.4	确定性训练与快照产物	40
6.1.5	评测指标与计算口径	40
6.1.6	统计与显著性检验	41
6.1.7	资源四项：测量流程与口径固定	41
6.2	主实验结果	42
6.2.1	稀疏观测 (SR 与 Crop) 下的重建性能	42
6.2.2	与 SOTA/代表基线对比	42
6.2.3	显著性检验结果	43
6.3	消融实验	43
6.3.1	去除 L_{spec}	43
6.3.2	去除 L_{dc}	43
6.3.3	H/DC 不复用 (故意错配)	43
6.3.4	解码器替换 (去除 “双线性 $+3\times 3$ ”)	43
6.3.5	频谱阈值扫描 (K 或 ρ_1, ρ_2)	44
6.4	可视化分析	44
6.4.1	标准图组与绘图规范	44
6.4.2	代表案例 (≥ 3)	44
6.4.3	失败案例与类型化诊断	44
6.5	资源与性能	45
6.5.1	Params 与 FLOPs	45
6.5.2	显存峰值与推理延迟	45
6.5.3	资源—性能折衷	45
6.6	结果小结与讨论	45
6.7	统计与可视化自检清单	45
6.8	YAML 字段到实验的映射	46
6.9	结果再现与汇总 (材料包结构)	46
第七章	结论	47
7.1	引言	47
7.2	一致性验证 (对应命题 1)	47
7.2.1	H/DC 等价性测试 (硬门槛)	47
7.2.2	评测口径一致性验证：相关性与 “断裂” 负例	48
7.3	收敛性与稳定性验证 (对应命题 2 与第四章稳定性讨论)	48
7.3.1	课程学习对收敛的影响 (SR $\times 2 \rightarrow \times 4$; Crop 40% $\rightarrow$ 20%)	48
7.3.2	因果/时序约束验证 (时序打乱负例)	49

目录	5
7.3.3 解码策略验证（双线性 +3×3 vs 反卷积）	49
7.4 泛化能力与跨网格鲁棒性（对应命题 3）	50
7.4.1 多分辨率外推评测（img_size = 128/256/512）	50
7.4.2 网格/离散化变化与别名诊断	50
7.5 显著性检验与效应大小（统一统计协议）	50
7.5.1 paired t-test（主指标 Rel-L2）	50
7.5.2 Cohen's <i>d</i> （配对版本）与置信区间	50
7.6 敏感性分析（参数—口径—资源三维折衷）	51
7.6.1 扫描维度与最小覆盖集	51
7.6.2 结果呈现模板（主表 + 附录）	51
7.7 可复现性验证（确定性、快照、指纹）	51
7.7.1 确定性配置与方差门槛	51
7.7.2 复现闭环材料检查	51
7.8 小结（命题 → 证据 → 材料）	52
第八章 附录	53
8.1 方法优势与机理解释	53
8.1.1 口径一致性带来的“评测可控性”	53
8.1.2 三件套损失的“互补约束结构”	53
8.1.3 统一接口与确定性训练提高“横向可比性”	53
8.2 局限性与风险点（更具体的“何时会变差”）	54
8.2.1 复杂几何与非周期边界下的谱域瓶颈	54
8.2.2 极端稀疏与高噪声下的权重敏感性	54
8.2.3 资源与流程成本上升	54
8.3 适用条件与工程实践建议（可操作）	54
8.4 未来工作（与本文框架强耦合的方向）	55
8.4.1 主动学习与自适应采样（信息效率）	55
8.4.2 弱式/变分物理约束与复杂边界融合	55
8.4.3 数据基准与跨任务扩展	55
8.5 小结	55
8.6 参考文献（APA）	55
第九章 致谢	57
9.1 本章概述	57
9.2 内容（占位）	57
参考文献	59

第一章 绪论

1.1 研究背景

1.1.1 稀疏观测下的时空场重建需求

在计算物理、环境监测与工程诊断等任务中，目标对象通常是定义在空间域 $\Omega \subset \mathbb{R}^2$ （可扩展到 $\mathbb{R}^3$ ）与时间区间 $[0, T]$ 上的连续物理场 $u(\mathbf{x}, t)$ ，例如速度场、压力场、温湿度场或浓度场。受限于传感器布设密度、采样带宽、测点维护与安全成本，真实系统往往只能获得有限测点、有限时间步且噪声与缺失并存的观测序列，从而形成“稀疏—噪声—不齐”的典型数据形态。

在该类条件下，上游观测不足会直接影响下游的预测、控制与诊断：预测依赖完整状态估计，控制依赖一致且可复用的观测口径，诊断依赖对异常结构（边界层、涡结构、锋面、热斑等）的稳定识别。由此产生的核心技术问题可概括为：在观测极稀疏且存在噪声与缺失的情况下，如何在连续时空域内恢复出高分辨率、可解释且与真实观测口径一致的物理场。

1.1.2 科学机器学习与算子学习的推动作用

近年来，面向偏微分方程（PDE）体系的学习方法快速发展：

- 物理约束学习以 PINN 为代表，将 PDE 残差与初边界条件并入训练目标，从而在数据不足时维持物理一致性框架 (Raissi et al., 2019)。
- 算子学习以 FNO、DeepONet 等为代表，学习“函数到函数”的映射，从而支持跨初值/参数族的快速推断，并在若干任务中展现跨分辨率或零样本超分辨潜力 (Li et al., 2021; Lu et al., 2021)。
- 更一般的数值分析与综述工作进一步系统化了物理信息学习方法的误差机理与适用边界 (De Ryck & Mishra, 2024)。

上述方法为稀疏观测重建提供了可行的建模工具，但工程落地仍常遭遇一个更基础的问题：训练阶段使用的退化/采样过程与评测阶段的真实观测口径不一致，导致“训练指标改善但评测口径误差不降”的断裂现象。该断裂不仅影响结论的可复现性，也会削弱模型在真实系统中的可部署性。

1.2 研究动机与应用场景

稀疏观测并非少数场景的例外，而是多数工程系统的常态。例如：

1. **城市微气候与污染监测**：传感器多部署在交通枢纽、关键建筑与少量基站，空间覆盖不足且维护频率不一致；
2. **海洋与大气观测**：遥感与浮标观测分辨率差异显著，时间戳不齐且信噪比受环境强影响；
3. **工业过程与管网系统**：复杂几何与高温高压环境降低传感器密度与可靠性，长期数据含漂移与间断；
4. **生物医学与材料过程成像**：采样成本与安全性约束导致观测稀疏，噪声与缺失不可避免。

上述应用共同指向两个需求：

- **高分辨率重建需求**：下游任务需要近似连续的高分辨率场；
- **口径一致性需求**：评测与部署依赖真实观测过程；训练阶段若未严格复用该口径，实验对比将难以审计，工程效果将难以预测。

基于此，本文将研究动机明确为：以“评测口径一致性优先”为原则，构建一套可复用、可审计、可复现的稀疏观测时空场重建框架，使数学意义的重建误差与观测意义的口径误差能够协同优化，并在统一资源约束下开展规范化对比。

1.3 研究问题定义与数学形式化

1.3.1 观测模型与重建目标

设真实高分辨率物理场为 $u(\mathbf{x}, t)$ 。观测由观测算子 H 与噪声项 n 生成：

$$y = H(u) + n. \quad (1.1)$$

其中 H 表示数据侧的采样/退化口径，覆盖下采样、裁剪、插值、边界处理与对齐策略等。重建模型 f_θ 在给定观测 y （及可选的显式坐标编码、掩码等）后输出预测场 $\hat{u}$ ：

$$\hat{u} = f_\theta(y; \theta). \quad (1.2)$$

本文关注的核心目标不是单一指标最小化，而是在统一口径约束下同时降低：

- **重建误差**（逼近真值的数学误差），以及
- **口径一致性误差**（预测经 H 作用后与观测 y 的一致性）。

1.3.2 任务口径：超分辨与裁剪（示例）

为覆盖典型的稀疏观测形态，本文将两类常见口径纳入统一形式：

- **超分辨（SR）口径**：下采样前引入低通预滤以抑制混叠，再采用面积插值进行降采样。OpenCV 文档指出缩小图像时可优先使用 `INTER_AREA` (OpenCV, [n.d.-a](#))。
- **裁剪（Crop）口径**：在中心对齐窗口内观测；窗口大小满足网络 patch 对齐要求，并显式声明边界策略（mirror/zero/wrap）。

上述口径强调一个工程事实：当观测生成依赖具体实现细节（预滤、插值、对齐、边界），训练与评测若不共享同一实现，实验结论将难以复核。

1.4 稀疏观测重建的关键挑战

1.4.1 混叠与频谱失真

下采样会将高频能量折叠到低频，造成不可逆信息损失。工程上常采用“先低通、再缩小”的抗混叠流程。OpenCV 的滤波教程对 `GaussianBlur` 的核大小与 σ 参数语义给出说明，为预滤实现提供可复用依据 (OpenCV, [n.d.-b](#))。在科学机器学习中，算子学习路线也讨论离散网格与表示差异导致的混叠/别名问题，并发展出“表示等价、别名无关”的设计框架，例如 ReNO (Bartolucci et al., [2023](#))。

1.4.2 训练口径与评测口径断裂

训练阶段退化过程与评测阶段真实观测口径不一致时，可能出现：重建误差指标下降，但口径一致性误差不降甚至恶化。该现象会造成横向对比不公与工程不可落地。解决路径要求：

- 数据侧观测算子 H 成为口径定义的唯一入口；
- 训练端退化算子 DC 与 H 同实现、同参数、同边界与同对齐策略（镜像复用）。

1.4.3 非周期边界与局部伪影扩散

非周期边界、复杂几何与掩码缺失会诱发边界伪影、振铃与局部能量偏差，且误差可能沿时间维传播，形成“局部失真—全局退化”的链式效应。该问题不仅影响像素级误差，也会影响谱域结构与下游诊断。

1.4.4 可复现性与可审计性

训练过程受随机种子、算子实现细节、库版本与硬件差异影响。科学结论需要在统一配置与多随机种子统计下保持稳定，并提供可审计的配置快照与环境指纹。

1.5 相关工作综述与定位（聚焦可落地引用）

1.5.1 物理约束学习：PINN

PINN 将 PDE 残差与初边界条件嵌入损失函数，在数据不足时可利用物理结构作为强先验。Raissi 等在 JCP 论文系统阐述了 PINN 的基本框架与典型用法 (Raissi et al., 2019)。与此同时，PINN 在多尺度、高维与复杂边界条件下的优化难度也在后续研究中持续被讨论。对本文而言，PINN 的启示在于：物理一致性约束可显著影响外推与稳健性；约束实现需与真实观测口径一致，否则约束项本身也可能引入偏差。

1.5.2 算子学习：FNO 与 DeepONet

FNO 在 Fourier 空间参数化积分核，从而学习 PDE 解算子的近似 (Li et al., 2021)。DeepONet 通过 branch/trunk 网络学习算子映射，并在 Nature Machine Intelligence 论文中从“算子通用逼近”角度进行系统论证 (Lu et al., 2021)。

与本文主题直接相关的一点在于：算子学习常在不同分辨率或不同网格上训练/推断，离散表示差异与混叠会显著影响泛化；统一口径与别名无关的设计成为提升跨网格鲁棒性的关键方向 (Bartolucci et al., 2023; Kovachki et al., 2023)。

1.5.3 物理信息与算子学习的结合：Physics-informed DeepONet

在缺乏成对输入输出监督时，引入 PDE 约束可作为有效正则；相应思路可视为将物理信息学习与算子学习进行融合。此处沿用“Physics-informed DeepONet”的常用称谓，并给出可核验检索入口：¹ 相关的误差机理与数值分析讨论可参见 Acta Numerica 综述 (De Ryck & Mishra, 2024)。

1.5.4 本文定位

本文不将贡献限定为单一网络结构微调，而是面向工程可复现与可部署需求，系统化“评测口径一致性优先”的研究框架：

- 以 H 作为口径定义的唯一入口；
- 以 DC 对 H 镜像复用，确保训练/评测一致；
- 在统一统计协议下进行显著性检验与资源约束对比；
- 形成可审计的材料产出链路，服务论文审查与后续复现。

¹<https://europepmc.org/article/pmc/pmc8480920>

1.6 研究内容与技术路线

1.6.1 总体路线

本文技术路线围绕“口径统一—算法构建—严格评测—材料产出”展开：

1. **口径统一**：以 H 固化观测生成流程（预滤、插值、对齐、边界），训练端 DC 与之完全复用；
2. **算法构建**：在统一模型接口下实现若干基线与改进方法，并保持输入打包（mask/coords/baseline）一致；
3. **严格评测**：多随机种子统计、显著性检验、资源四项透明报告；
4. **材料产出**：配置快照、环境指纹、指标表、代表图与失败案例归档。

1.6.2 指标体系与一致性目标

本文采用两类误差作为核心指标：

- **相对重建误差（Rel-L2）**：

$$\text{Rel-L2} = \frac{\|\hat{u} - u\|_2}{\|u\|_2}. \quad (1.3)$$

- **口径一致性误差（ H_{err} ）**：

$$H_{\text{err}} = \|H(\hat{u}) - y\|_2. \quad (1.4)$$

二者同步下降意味着：预测在数学意义上逼近真值，并在观测意义上与真实测量口径一致。

1.6.3 损失设计（示意）

训练阶段采用由三部分构成的目标函数（以原值域计算一致性项）：

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \lambda_{\text{spec}} \mathcal{L}_{\text{spec}} + \lambda_{\text{dc}} \mathcal{L}_{\text{dc}}. \quad (1.5)$$

其中：

- $\mathcal{L}_{\text{rec}}$ ：重建损失（原值域或统一尺度域）；
- $\mathcal{L}_{\text{spec}}$ ：低频谱一致性，用于约束大尺度结构；
- $\mathcal{L}_{\text{dc}} = \|H(\hat{u}) - y\|_2^2$ ：以真实口径约束训练过程，使模型对观测过程保持一致性。

1.7 创新点与主要贡献（面向论文审查口径）

1. 提出“评测口径一致性优先”的方法论框架：将 H 作为观测口径的唯一入口，并要求训练端 DC 镜像复用 H 的实现与参数，从机制上消除训练/评测断裂。
2. 构建兼顾重建与口径一致性的目标函数：通过显式的口径一致性项推动 H_{err} 与 Rel-L2 协同改善。
3. 形成可复现、可审计的评测协议：多随机种子统计与显著性检验，并同步报告资源四项（参数量、计算量、显存峰值、推断延迟），提升对比结论的工程可信度。
4. 配套材料产出与失败案例归档：输出指标主表、显著性报告、代表案例与失败类型分析，为后续章节实验复核与讨论提供可追溯证据链。

1.8 论文结构安排

- 第 2 章：相关工作综述与问题定位；
- 第 3 章：观测口径统一的数学形式化、模型接口与损失设计；
- 第 4 章：一致性与鲁棒性分析（含混叠与边界因素讨论）；
- 第 5 章：算法实现与关键工程细节（观测算子实现、训练流程、统计脚本）；
- 第 6 章：实验设置、主结果、消融与显著性检验、资源成本报告；
- 第 7 章：理论与现象对应验证（跨分辨率、跨网格敏感性等）；
- 第 8 章：讨论与局限；
- 第 9 章：结论与展望。

1.9 研究伦理与合规

本文遵循研究生论文对学术规范与工程合规的要求：

- 数据与代码遵循可公开许可或仅在授权范围内使用；
- 结果汇报遵循可复核原则（配置快照、环境指纹、统计协议）；
- 不隐去失败案例，采用类型化归档与可操作改进建议支持后续工作。

1.10 本章小结

本章从稀疏观测的工程现实出发，说明时空流场重建在多类应用中的共性需求与关键困难，梳理 PINN 与算子学习（FNO、DeepONet）等代表性方法的核心思想，并指出训练口径与评测口径不一致引发的可复现性与可部署性风险。围绕该风险，本文提出“评测口径一致性优先”的研究路线，并给出统一指标体系、损失设计思路与可审计的评测/材料产出框架，为后续章节的方法论、算法与实验展开奠定基础。

1.11 关键术语表（本章使用口径）

表 1.1: 关键术语表（本章口径）

术语	定义
观测算子 H	数据侧采样/退化口径（预滤、插值、对齐、边界等实现细节的集合）
训练退化 DC	训练端复用的观测算子实例，与 H 同实现同参数
H_{err}	$\ H(\hat{u}) - y\ $ ，评测口径一致性误差
Rel-L2	$\ \hat{u} - u\ _2 / \ u\ _2$ ，重建相对误差
抗混叠	下采样前低通预滤降低混叠风险；缩小时常用 INTER_AREA (OpenCV, n.d.-a)
低频谱一致性	比较低频 Fourier 模态以约束大尺度结构一致性

第二章 相关工作

2.1 引言

稀疏观测驱动的时空流场重建 (sparse-to-full spatiotemporal field reconstruction) 处于科学机器学习 (SciML) 与计算流体/计算物理交叉地带。相关研究大体沿两条主线发展：

1. **物理约束学习**：以 Physics-Informed Neural Networks (PINN) 为代表，通过在损失中嵌入 PDE 残差、初边界条件与观测约束，强调物理一致性与可解释性；典型工作为 Raissi 等提出的 PINN 框架 Raissi et al., 2019。
2. **算子学习 (Neural Operator / Operator Learning)**：以 Fourier Neural Operator (FNO) 与 DeepONet 等为代表，学习“函数到函数”的映射（即 PDE 解算算子或其近似），强调跨参数/跨初值的快速推理与外推能力；系统性论述可参考 Kovachki 等在 JMLR 的 neural operator 工作 Kovachki et al., 2023。

除方法路线外，稀疏观测重建还长期被三个工程问题持续“卡脖子”：

- **观测口径与训练口径是否一致**：观测算子 H 与训练端退化算子 DC 是否一致/复用；
- **离散化与别名 (aliasing) 是否影响跨分辨率/跨网格泛化**：分辨率变化、插值/边界处理变化会否触发系统性性能退化；
- **评测协议与复现实验是否足够严格**：统一指标、统计显著性与资源成本透明化是否到位。

本章围绕上述维度，对关键文献进行综述与批判性归纳，并在章末给出“方法—理论—基准—问题”的关系框架与对照维度表，为第三章的方法论形式化与第四章的评测设计提供直接支撑。

2.2 问题范式与两类核心路线：PINN 与算子学习

2.2.1 PINN：以物理残差为关键的约束学习

PINN 的核心思想是：在神经网络逼近解函数 $u_\theta(\mathbf{x}, t)$ 的同时，将 PDE 残差、初边界条件与观测误差统一写入损失函数，从而在数据稀缺或观测受限场景中利用物理规律“补信息”。该范式由 Raissi 等提出并系统化 Raissi et al., 2019。

PINN 的研究价值主要体现在：

1. 对观测稀缺的天然适配：可在少量观测下用 PDE 约束收缩解空间；
2. 对下游任务的可解释性：PDE 残差与边界条件违反程度可被审计；
3. 对反问题的统一表达：可把未知参数（系数、源项）纳入可学习变量。

与此同时，近年研究也指出 PINN 在多尺度、刚性（stiff）或高维问题上可能出现训练困难与收敛失败。Wang 等从神经切线核（NTK）视角分析“何时、为何 PINN 难以训练”，为损失权重、采样策略与网络结构设计提供解释框架 S. Wang, Yu, and Perdikaris, 2022。

2.2.2 算子学习：从“拟合单个解”转向“学习解算子”

与 PINN 的“拟合单个方程实例解”不同，算子学习目标是学习映射

$$\mathcal{G} : a(\cdot) \mapsto u(\cdot), \quad (2.1)$$

其中 $a(\cdot)$ 可表示系数场/初值/源项等函数输入， $u(\cdot)$ 为解函数。该路线旨在在同一类 PDE 上实现跨参数/跨初值快速推理。Kovachki 等在 JMLR 系统化“Neural Operator”框架，并强调其离散化不变（discretization-invariant）建模动机与形式化 Kovachki et al., 2023。

在工程上，算子学习的优势集中体现在：

- 推理速度：可替代传统 PDE 求解器的多次迭代；
- 批量推理与外推：适合数据驱动的参数扫描与不确定性分析；
- 与深度网络工程栈兼容：可结合编码器/Transformer/UNet 等架构。

FNO 属于 neural operator 的关键实例之一；其 ICLR 2021 论文与配套材料给出典型应用与效率对比场景 Li et al., 2021。

2.2.3 DeepONet：算子近似的分支—主干结构

DeepONet 将算子近似写为“分支网络编码输入函数 + 主干网络编码查询点”，适合处理不规则采样与函数输入。其代表性论文发表于 *Nature Machine Intelligence* Lu et al., 2021。

在“稀疏观测 → 全场重建”任务中，DeepONet 的结构优势常体现在：对输入观测点集合与查询点集合的自然解耦、对网格变化的适配潜力，以及与物理约束项（PDE 残差、边界条件）结合的便利性 Lu et al., 2021。

2.3 稀疏观测与退化建模：观测算子、抗混叠与口径一致性

2.3.1 稀疏观测的“信息瓶颈”与退化算子表述

稀疏观测可统一写为：

$$y = H(u) + n, \quad (2.2)$$

其中 u 为高分辨率真值场， H 为观测算子（下采样、裁剪、点采样、投影、卷积模糊等）， n 为噪声。该表述既适用于遥感/浮标类观测，也适用于工业管网/风洞测点类观测。

此处关键不在公式本身，而在于： H 的定义决定“评测口径”。若训练端使用的退化过程与评测端观测口径不一致，将引入难以察觉的域偏差，造成“指标虚优或不可复现”的风险。该判断属于方法学归纳：后续章节将给出本文的制度化约束与自检脚本，并将其写成可执行协议。

2.3.2 抗混叠（anti-aliasing）在下采样口径中的必要性

对超分辨或降采样观测，抗混叠的基本原则是：在缩小分辨率前抑制高频分量，以避免混叠带来的不可逆信息折叠。

工程实现中，OpenCV 官方文档指出：进行图像缩小（decimation）时，通常推荐使用 INTER_AREA 插值 OpenCV, n.d.-a。同时，GaussianBlur 属于常用低通平滑算子；OpenCV 官方教程给出其接口与参数语义（核大小、 σ 、边界处理等）OpenCV, n.d.-b。

据此，可落地的口径选择通常采用“低通预滤 + 面积插值缩小”的组合：

- 低通预滤：GaussianBlur（控制 σ 、kernel size 与边界处理）OpenCV, n.d.-b；
- 缩小插值：INTER_AREA（优先用于 downsampling）OpenCV, n.d.-a。

说明：上述两条属于“工具文档可核验事实”；而“为何低通能抑制混叠”属于信号处理基础原理（Nyquist/频域折叠），通常不依赖单一论文出处。

2.3.3 口径一致性 (H 与 DC) 与可复现评测

文献层面, PDEBench 强调基准化数据与评测的重要性, 并通过 OpenReview 给出基准描述、代码与数据获取方式 Takamoto et al., 2022; 其数据发布条目同时提供可检索的公开数据标识 (含数据集 DOI/仓储信息) Takamoto et al., 2022。

在稀疏观测重建问题上, “口径一致性”的工程含义可概括为:

- 数据侧观测算子 H 决定观测生成与评测口径;
- 训练侧退化 DC 若用于合成观测或一致性损失, 宜与 H 保持实现与参数一致;
- 当研究目标面向工程部署, 训练—评测—部署三者口径需要闭环一致。

上述三点中, 前两点可通过工具链与数据管线直接落地; 第三点属于本文面向应用的研究立场, 将在第三章与第四章被形式化为可执行协议。

2.4 时空耦合建模与训练偏置: 多尺度、频谱偏置与因果性

2.4.1 时空结构的多尺度性与频谱偏置问题

湍流/对流/波动类流场往往呈现宽频谱特性, 模型在训练中可能出现“对某些频段更易拟合”的偏置。近年工作针对 PINN/神经网络的频谱偏置缓解提出多类策略, 例如通过 (空间) 自适应 Fourier 特征编码削弱偏置并改善高频学习 Liu et al., 2025。

相关研究指向一个一致结论: 频谱偏置并非仅是网络表达力问题, 优化动态、编码方式与损失设计共同决定频段学习的先后顺序与稳定性 Liu et al., 2025。

因此, 面向“稀疏 $\rightarrow$ 全场”的重建任务, 相关工作的经验通常支持三类改进方向:

1. 输入编码: Fourier 特征或多尺度位置编码;
2. 谱域约束: 在损失中显式约束低频/中频结构一致性;
3. 结构化解码与抗伪影: 减少插值与上采样带来的棋盘格/振铃伪影。

其中 (2) (3) 更容易形成稳定可复现的工程管线, 原因在于其对数据与网络结构的改动幅度可控。

2.4.2 因果性与时序稳定性: 从 PINN 到算子序列建模

时间维度建模常面临滚动误差累积与稳定性问题。Wang 等提出“Respecting causality is all you need for training physics-informed neural networks”, 强调训练时尊重时间

因果结构可改善 PINN 训练稳定性与长期预测表现S. Wang, Sankaran, and Perdikaris, 2022。

在算子学习路线下, 时序建模也可通过自回归 (AR)、序列到序列 (Seq2Seq), 或将时间作为额外维度输入等方式实现; 不同策略在误差传播与推理成本方面存在权衡。该权衡将直接影响第4章的评测设计与资源对比口径设置。

2.4.3 与稀疏观测重建的关系

综合相关工作, 可得到更“可落地”的经验链:

- 观测稀疏导致高频细节不可辨识;
- 频谱偏置使高频恢复进一步困难;
- 因果结构与时序稳定性决定长时重建/预测的误差是否可控。

因此, 将频谱一致性与观测一致性显式纳入损失与评测, 往往比单纯扩大模型容量更具稳定收益。该结论属于方法学归纳, 具体实现与消融将在后续章节展开。

2.5 离散化误差与别名 (aliasing): 跨网格鲁棒性的关键障碍

算子学习强调函数空间映射, 但训练与推理最终落到离散网格/离散采样点。当离散化方式变化 (分辨率变化、采样点变化、插值方式变化) 时, 模型可能出现表示别名与跨网格性能退化。Kovachki 等在 neural operator 工作中讨论了离散化不变建模的动机与形式化框架Kovachki et al., 2023。

为直接应对别名问题, Bartolucci 等提出 Representation Equivalent Neural Operators (ReNO), 目标是缓解离散表示差异导致的别名效应并提升跨离散化设置的可靠性Bartolucci et al., 2023。

对“稀疏观测 $\rightarrow$ 全场”的任务而言, 别名问题常通过两类现象暴露:

- 分辨率变化时, 低频结构看似正确但高频细节严重漂移;
- 评测口径变化 (不同插值/边界处理) 时, 指标出现不可解释波动。

因此, 跨网格鲁棒性评测不宜仅使用单一分辨率或单一口径; 相关工作作为本文在第4章设置“跨分辨率/跨口径敏感性分析”提供直接依据Bartolucci et al., 2023。

2.6 基准与数据：PDEBench 的意义与边界

PDEBench 提供多类 PDE 的数据、代码与基线方法，用于系统化对比科学机器学习模型Takamoto et al., 2022。其公开发布的信息为复现实验与结果审计提供基础条件Takamoto et al., 2022。

需要指出的是，基准的存在并不自动保证“稀疏观测重建”的评测公平：

- 若任务引入自定义观测算子（下采样、裁剪、噪声模型），则“观测生成口径”必须在实验材料中被明确声明；
- 若训练端使用额外的退化/一致性约束，则训练端退化与评测端观测口径之间的对应关系必须可审计。

因此，PDEBench 更适合作为“数据与基本协议的共同底座”，而观测口径与一致性约束需要在具体研究中额外制度化（该点构成本文在第三章提出统一口径协议的直接动机）。

2.7 统计检验与工程成本：从“论文结果”走向“可部署结论”

2.7.1 多种子统计与效应量

机器学习实验对随机种子敏感已是共识；仅报告单次结果容易造成结论不稳健。统计意义上的稳健结论往往需要：

- 多次重复实验报告均值与方差；
- 在主对照上做显著性检验；
- 给出效应量以量化实际改进幅度。

效应量（如 Cohen’s d ）在统计分析中的定义与解释可追溯到 Cohen 的经典著作Cohen, 1988。

说明：本文后续采用的“ ≥ 3 种子、paired t -test、Cohen’s d 、资源四项”等属于本文拟定的评测协议，与“统计学工具可核验定义”不同；统计工具本身的出处如上所示。

2.7.2 资源成本透明化

对工程部署而言，参数量、FLOPs、显存峰值与推理延迟决定可落地性。相关工作通常以“速度/精度权衡”呈现算子学习优势，例如 FNO 工作在效率与精度方面给出典型对比Li et al., 2021。因此，相关工作部分需要把“精度提升”与“成本变化”放在同一评价框架内讨论，而不是仅以误差指标排序。

表 2.1: 面向稀疏观测重建的关键方法对照（评审维度组织）。

方法类别	代表工作	物理约束 显式程度	跨网格/跨分辨率 讨论	对稀疏观测的适 配性	主要风险点	与本文关注点的接 口
物理约束学 习	PINN Raissi et al., 2019	高	视实现而定	强（可直接写观测损失）	训练不稳定/多尺度困难 S. Wang, Yu, and Perdikaris, 2022	观测一致性损失、因果/采样策略 S. Wang, Sankaran, and Perdikaris, 2022
算子学习（谱域）	Neural Operator / FNOLi et al., 2021	中（需外加约束）	强调离散化不变动机 Kovachki et al., 2023	强（学习函数 $\rightarrow$ 函数映射）	别名/口径差异导致泛化波动	统一观测口径 + 频谱一致性项
算子学习（采样友好）	DeepONetLu et al., 2021	中（需外加约束）	具潜力（依赖实现）	强（分支/主干适合不规则点）	训练成本与表达/泛化权衡	与稀疏点集输入、坐标编码对齐
别名无关/等价表示	ReNOBartolucci et al., 2023	与主干方法相关	直接针对 aliasing	间接（更偏离散化鲁棒）	理论与实现复杂度提升	跨分辨率敏感性分析与负例对照

2.8 文献关系框架与对照维度（可直接用于论文配图/配表）

2.8.1 “方法—理论—基准—问题” 四象限关系框架（文字版）

- **方法（Methods）**: PINN（物理残差约束）Raissi et al., 2019, FNO/DeepONet（算子学习）Li et al., 2021; Lu et al., 2021。
- **理论（Theory）**: PINN 训练失败机制（NTK 视角）S. Wang, Yu, and Perdikaris, 2022, 因果性约束S. Wang, Sankaran, and Perdikaris, 2022, 频谱偏置缓解Liu et al., 2025。
- **基准（Benchmark）**: PDEBench（数据、协议、基线）Takamoto et al., 2022。
- **问题（Issues）**: 离散化别名与跨网格鲁棒性（ReNO）Bartolucci et al., 2023, 观测口径与评测一致性（由观测算子定义驱动）。

该框架的直接用途: 第三章在“问题象限”落地观测算子与口径协议; 第四章在“基准象限”对齐数据与指标, 并在“理论象限”指导消融与敏感性分析设置。

2.8.2 关键方法对照表（面向稀疏观测重建的评审维度）

2.9 符号与记号对齐（与第 3 章接口，避免跨章歧义）

为保证后续数学形式化与实现描述一致，本章采用的符号约定如下（第三章将给出完整符号表与严格定义）:

- u : 高分辨率真值场（spatiotemporal field）;

- y : 观测（稀疏/退化后信号）;
- H : 观测算子（定义观测生成与评测口径）;
- DC : 训练端退化算子（若用于一致性约束，需与 H 对齐）;
- $\hat{u}$ 或 $\hat{y}$: 模型预测;
- $\Omega \subset \mathbb{R}^2$ 、 $t \in [0, T]$: 空间域与时间域;
- $\mathcal{G}$: PDE 解算子/学习到的算子映射Kovachki et al., 2023。

2.10 本章小结与章节过渡

相关工作表明:

1. PINN 与算子学习分别从“物理约束”与“函数空间映射”两端提供解决路径，二者具有互补性Kovachki et al., 2023; Raissi et al., 2019;
2. 稀疏观测重建在工程上高度依赖观测算子口径，抗混叠与插值策略具备明确可复现的工具链依据（例如 OpenCV 中 `INTER_AREA` 常用于缩小分辨率）OpenCV, n.d.-a;
3. 跨分辨率/跨网格泛化受到离散化别名影响，ReNO 等工作作为“别名一鲁棒性”提供明确研究方向与评测动机Bartolucci et al., 2023;
4. 频谱偏置与因果性约束等理论线索，为损失设计与时序稳定性提供可解释的改进空间Liu et al., 2025; S. Wang, Sankaran, and Perdikaris, 2022。

基于上述归纳，第三章将把“观测口径一致性”提升为可执行的形式化约束，给出观测算子 H 与训练端退化 DC 的统一定义方式，并在统一接口下推导损失与训练流程；第四章将在 PDEBench 底座上构建可审计的评测与统计检验协议，并通过跨分辨率/跨口径的敏感性分析验证结论稳健性Takamoto et al., 2022。

第三章 方法

本章给出面向“稀疏观测驱动的时空场重建”的可复现、可审计、可工程落地的方法学框架。方法设计围绕两类硬约束展开：(i) **采样/退化口径一致**：数据侧观测算子 H 与训练侧退化算子 DC 复用同一实现与参数；(ii) **评测口径内生**：除重建误差外，引入观测口径一致性约束，使 $H(\hat{u})$ 与观测 y 在同一口径下对齐。

3.1 问题定义与数学形式化

设连续空间域 $\Omega \subset \mathbb{R}^2$ ，离散网格为 Ω_h ，空间分辨率记为 $N_x \times N_y$ ；离散时间索引 $t \in \{1, \dots, T\}$ 。目标场为标量或多通道场

$$u_t : \Omega_h \rightarrow \mathbb{R}^C, \quad u_{1:T} = \{u_t\}_{t=1}^T. \quad (3.1)$$

给定观测算子 H （包含滤波、采样/下采样、裁剪、边界处理与插值对齐等实现细节）与噪声项 n_t ，观测为

$$y_t = H(u_t) + n_t. \quad (3.2)$$

学习映射 Φ_ω ，以观测序列与辅助信息恢复全场：

$$\hat{u}_{1:T} = \Phi_\omega(y_{1:T}, m_{1:T}, p), \quad (3.3)$$

其中 m_t 为观测掩码（稀疏口位置或缺失区域标注）， p 为显式坐标/位置编码（可含 Fourier 特征）。

为避免“数学域指标改善但评测口径误差不降”的断裂现象，本研究同时关注两类误差：

- **重建域误差**：如 Rel-L2、MAE 等；
- **观测口径误差（H-一致性误差）**：

$$H_{\text{err}} \triangleq \|H(\tilde{u}) - y\|_2, \quad (3.4)$$

其中 $\tilde{u}$ 为回到原值域的预测（见[section 3.5](#)）。

3.2 统一观测算子 H ：抗混叠与口径声明

稀疏观测重建的关键在于：观测过程是否丢失不可恢复的信息，以及训练与评测是否处于同一口径。对 SR（下采样）观测，工程上常采用“先低通、再缩小”的抗混叠流程；OpenCV 在插值枚举中明确指出：INTER_AREA 在图像缩小时通常更优，并与“moire-free”重采样相关联。

3.2.1 SR 观测口径（下采样）

对缩小倍率 s ，本文将 SR 观测写为

$$y_t^{\text{SR}} = D_s(G_{\sigma_{\text{blur}}} * u_t) + n_t, \quad (3.5)$$

其中 $G_{\sigma_{\text{blur}}}$ 为高斯低通核， D_s 为下采样算子。实现层面需显式声明并写入配置：核大小 k 、 σ_{blur} 、插值策略（缩小优先 INTER_AREA）、边界处理与对齐规则等。

3.2.2 Crop 观测口径（裁剪）

Crop 观测写为

$$y_t^{\text{Crop}} = C_{h_c, w_c}(u_t) + n_t, \quad (3.6)$$

其中 C_{h_c, w_c} 为中心对齐裁剪算子。裁剪任务口径主要来自对齐规则与边界策略，需显式声明：中心对齐/偏移定义、 (h_c, w_c) 与 patch-size 的整倍数约束、边界策略、mask 是否同步裁剪等。

3.3 H/DC 单一口径复用：硬约束与阻断式审计

3.3.1 硬约束：训练退化 $DC \equiv H$

定义训练侧退化一致性算子 DC 。本文采用硬约束：

$$DC \equiv H \quad (\text{同一实现、同一参数、同一边界与插值/对齐策略}). \quad (3.7)$$

3.3.2 阻断式等价性检验（不通过则不进入统计）

为把“口径一致性”从写作承诺落到可执行证据链，训练流程在进入统计之前执行阻断式审计：对随机抽样样本 $u^{(i)}$ ，比较 $H(u^{(i)})$ 与 $DC(u^{(i)})$ 的差异；若超过阈值 ε ，直接终止该实验配置并归档差异报告。高斯滤波接口中关于 σ 、核大小与 `borderType` 的参数语义可追溯到 OpenCV 官方函数文档。

（伪代码与归档路径见[算法 1](#)。）

3.4 模型接口：统一输入打包与可替换算子层

3.4.1 统一输入打包（接口契约）

以单帧为例，输入在通道维拼接：

$$x_t = \text{Concat}(\text{baseline}(y_t), m_t, \text{coords}, \text{PE}_{\text{Fourier}}). \quad (3.8)$$

其中 baseline 可取简单插值/上采样，用于稳定训练起点；Fourier 特征常用于提升高频函数拟合能力。

统一模型签名（便于横向替换与统一评测）：

$$\text{forward} : \mathbb{R}^{B \times C_{\text{in}} \times N_x \times N_y} \rightarrow \mathbb{R}^{B \times C_{\text{out}} \times N_x \times N_y}. \quad (3.9)$$

3.4.2 算子学习视角（方法定位）

从“函数到函数映射”的角度，神经算子框架强调离散化不变的建模动机，并系统讨论了 Fourier neural operator 等高效参数化类别。本研究把“算子层”抽象为可替换模块，用于在统一接口下对比 FNO-family、Conv-Attn hybrid 等实现，同时同步报告资源成本。

3.5 三件套损失：重建、低频谱一致性、原值域观测一致性

3.5.1 标准化域与原值域

逐通道 z-score：

$$u^{(z)} = \frac{u - \mu}{\sigma_z}, \quad \tilde{u} = \sigma_z \hat{u}^{(z)} + \mu. \quad (3.10)$$

其中 $\tilde{u}$ 用于计算与观测口径一致的损失项，避免尺度不一致导致的优化偏差。

3.5.2 重建损失 L_{rec}

$$L_{\text{rec}} = \|\hat{u}^{(z)} - u^{(z)}\|_2^2. \quad (3.11)$$

3.5.3 低频谱一致性损失 L_{spec}

二维 FFT 后仅在低频集合 $\mathcal{K}_{\text{low}}$ 上比较：

$$L_{\text{spec}} = \sum_{(k_x, k_y) \in \mathcal{K}_{\text{low}}} |\mathcal{F}_{2D}(\hat{u}^{(z)})_{k_x, k_y} - \mathcal{F}_{2D}(u^{(z)})_{k_x, k_y}|^2, \quad \mathcal{K}_{\text{low}} = \{k_x \leq K, k_y \leq K\}. \quad (3.12)$$

3.5.4 原值域观测一致性损失 L_{dc}

用统一口径 H 直接约束评测口径误差：

$$L_{dc} = \|H(\tilde{u}) - y\|_2^2. \quad (3.13)$$

3.5.5 总损失

$$L = L_{rec} + \lambda_s L_{spec} + \lambda_{dc} L_{dc}. \quad (3.14)$$

3.6 复现闭环：配置快照、环境指纹与一致性归档

方法章内置复现闭环产物（训练完成自动写入）：

- runs/<exp>/config_merged.yaml（配置快照）；
- runs/<exp>/env_fingerprint.json（CUDA/驱动、PyTorch、AMP、随机种子等）；
- runs/<exp>/consistency_report.json（ H/DC 审计报告）；
- runs/<exp>/metrics_by_seed.csv（多种子结果表）。

3.7 研究设计：对照、消融与敏感性分析

核心消融见 Table 3.2；敏感性分析建议把 s, σ_{blur}, k 、边界策略、低频阈值 K 、Fourier 特征维度与频带等纳入扫描，并同步输出误差与资源四项。

3.8 统计检验：显著性与效应量

为避免单次结果偶然性，本文采用同配置下不少于 3 个随机种子，报告均值 $\pm$ 标准差；并在主对照上使用 paired t-test 与配对效应量（Cohen's d ）共同报告，效应量报告实践可参考 Lakens 的指南。

3.9 与 PINN 物理残差约束的关系（边界定位）

PINN 通过 PDE 残差引入物理一致性，但在多尺度/混沌/湍流动力系统上可能受训练可达性影响。因果结构被用于改善 PINN 训练稳定性并扩展可解问题范围。因此本文把 PDE 残差项定位为可选正则或对照基线，主方法定位为“统一口径下的时空模型 + 观测一致性约束”。

表 3.1: 观测口径参数表（SR 与 Crop）

口径类型	需显式声明的参数（论文与 YAML 同步）
SR（下采样）	缩小倍率 s ；高斯核大小 k 与 σ_{blur} ；缩小插值（建议 INTER_AREA）；边界策略（reflect/replicate/wrap/constant）；滤波是否共享同一边界策略；对齐规则（像素中心定义、rounding 规则）；噪声模型与强度。
Crop（裁剪）	窗口大小 (h_c, w_c) ；中心对齐与偏移定义；与 patch-size 的整倍数约束；边界策略；mask 是否同步裁剪与对齐；噪声模型与强度。

表 3.2: 消融实验设置（A0–A3）

设置	L_{rec}	L_{spec}	L_{dc}
A0（仅重建）	✓		
A1（+ 口径一致性）	✓		✓
A2（+ 低频谱一致性）	✓	✓	
A3（主方法：三件套）	✓	✓	✓

Algorithm 1 H/DC 等价性阻断式审计（不通过则不进入统计）

```

1: 输入：实现  $H(\cdot)$ ，实现  $DC(\cdot)$ ，抽样数  $N \geq 100$ ，阈值  $\varepsilon$ 
2: for  $i = 1$  to  $N$  do
3:   抽样  $u^{(i)}$ （原值域）
4:    $y_H \leftarrow H(u^{(i)})$ 
5:    $y_{DC} \leftarrow DC(u^{(i)})$ 
6:    $e_i \leftarrow \text{MSE}(y_H, y_{DC})$ 
7: end for
8: if  $\max_i e_i \geq \varepsilon$  then
9:   归档：runs/<exp>/consistency_report.json（差异来源、参数快照、样本索引）
10:  终止：该配置不进入训练与统计
11: else
12:  通过：进入训练与后续统计
13: end if

```

第四章 实验设置

4.0 引言

稀疏观测驱动的时空流场重建本质上是一个欠定逆问题：观测算子 H 往往不可逆，单纯依赖观测一致性并不能唯一确定高分辨率真值场。本文方法的关键并非“把欠定问题变成可解”，而是通过三类互补约束，使学习过程在可解释、可检验、可复现的条件下收敛到一个“评测口径一致且结构合理”的解：

- (1) **观测口径一致性 (H/DC 复用)**：训练侧退化算子 DC 与数据侧观测算子 H 使用同一实现与同一参数，避免“训练口径一评测口径不一致”导致的断裂；
- (2) **三件套损失**： $L_{\text{rec}} + \lambda_s L_{\text{spec}} + \lambda_{dc} L_{dc}$ ，分别约束点对点、低频结构与观测一致性；
- (3) **统一接口与确定性训练**：通过固定配置快照、随机种子与确定性算子策略，使实验结论具有可复验性（复现闭环），并遵循 PyTorch 可复现性建议与限制说明 PyTorch Contributors, [n.d.-b](#).

在理论层面，本章回答三个核心问题：

- 为什么 H/DC 复用可将“评测口径误差 $H_{\text{err}} = \|H(\tilde{u}) - y\|_2$ ”与“重建误差 $\|\tilde{u} - u\|_2$ ”重新绑定？
- 为什么 低频谱一致性可以显著提升大尺度结构与跨网格稳定性？
- 为什么 神经算子/多尺度网络 + 统一口径能在离散化与混叠问题上获得更稳健的泛化？

4.1 预备定义：函数空间、算子范数与误差度量

令 $\Omega \subset \mathbb{R}^2$ ，时间 $t \in [0, T]$ 。对每个时刻 t ，真值场 $u_t \in \mathcal{X}$ （可取 $L^2(\Omega)^C$ ，或离散网格上的 $\mathbb{R}^{N_x \times N_y \times C}$ ）。观测为

$$y_t = H(u_t) + n_t, \quad (4.1)$$

其中 $H: \mathcal{X} \rightarrow \mathcal{Y}$ 为（离散实现的）有界线性算子或近似线性算子（典型如卷积、下采样、裁剪）， n_t 为噪声。

本文在原值域定义评测口径误差

$$H_{\text{err}}(t) \triangleq \|H(\tilde{u}_t) - y_t\|_2, \quad (4.2)$$

而常用重建误差（如 Rel-L2）可写为

$$\text{Rel-L2}(t) = \frac{\|\tilde{u}_t - u_t\|_2}{\|u_t\|_2}. \quad (4.3)$$

关键点：若训练时的退化算子 DC 与评测时的 H 不一致，则训练得到的“数据一致性”并不等价于评测口径下的一致性，导致 H_{err} 与 Rel-L2 的趋势可能分裂（第 2 章称为“评测断裂”）。

4.2 观测口径一致性（ H/DC 复用）的可证明意义

4.2.1 命题 4.1：评测口径误差由重建误差上界控制（前提：同一 H ）

命题 4.1 (评测一致性上界). 若 H 为有界线性算子，则对任意预测 $\tilde{u}$ 有

$$\|H(\tilde{u}) - H(u)\|_2 \leq \|H\|_{\text{op}} \|\tilde{u} - u\|_2, \quad (4.4)$$

其中 $\|H\|_{\text{op}}$ 为算子范数。进一步，若 $y = H(u) + n$ ，则

$$\underbrace{\|H(\tilde{u}) - y\|_2}_{H_{\text{err}}} \leq \|H\|_{\text{op}} \|\tilde{u} - u\|_2 + \|n\|_2. \quad (4.5)$$

证明思路（素描）。由线性有界算子的定义， $\|H(v)\|_2 \leq \|H\|_{\text{op}} \|v\|_2$ ，令 $v = \tilde{u} - u$ 得式(4.4)。再由三角不等式与 $y = H(u) + n$ ，

$$\|H(\tilde{u}) - y\|_2 = \|H(\tilde{u}) - H(u) - n\|_2 \leq \|H(\tilde{u}) - H(u)\|_2 + \|n\|_2,$$

结合式(4.4) 即得式(4.5)。 $\square$

该命题解释了：当且仅当训练与评测使用同一 H （即 $DC \equiv H$ 的严格复用）时，降低重建误差才会稳定传导到评测口径误差，从而为“强制 H/DC 复用”提供直接理论支撑。类似的“训练误差 $\rightarrow$ 泛化误差”的链式控制思想在 PINN 的误差与数值分析语境中也经常出现 De Ryck and Mishra, 2022, 2024。

4.2.2 SR 与 Crop 两类 H 的算子稳定性：为何 $\|H\|_{\text{op}}$ 往往温和

- **Crop**（居中裁剪）：可视为离散向量的坐标子集选择（restriction）。在 ℓ_2 范数下，裁剪不会放大能量，因此 $\|H\|_{\text{op}} \leq 1$ 。
- **SR**（Gaussian 预滤 + 下采样）：高斯卷积为平滑算子；缩小采样若使用面积插值（OpenCV 的 INTER_AREA）属于典型的“缩小推荐插值”实践，目标之一是减轻缩小过程的混叠伪影 OpenCV, n.d.-a, n.d.-b。

表 4.1: DC Equivalence Audit Template (Hard Threshold Test)

Audit Item	Tolerance (ε)	Action on Fail
Kernel Size Consistency	0	Block
Sigma Value (σ)	10^{-6}	Block
Border Handling	Identical	Block
Output Norm Difference	10^{-5}	Block

因此，对 SR 与 Crop 两类任务，命题4.1中的 $\|H\|_{\text{op}}$ 通常不会异常巨大，使得“评测口径误差受控于重建误差”的结论具有工程可操作性。

4.2.3 欠定性与必要补充：为何仅 L_{dc} 不够

即便 DC 与 H 完全一致，若只最小化

$$L_{dc} = \|H(\tilde{u}) - y\|_2^2, \quad (4.6)$$

仍可能出现多个 $\tilde{u}$ 同时满足 $H(\tilde{u}) \approx y$ （尤其在稀疏/降采样场景）。这并非方法缺陷，而是逆问题的固有性质。本文引入 L_{rec} 与 L_{spec} 的意义在于：用“点对点逼近 + 低频结构先验”把可行解集合缩到更合理的子空间，从而在真实评测口径下实现稳定提升。

4.3 三件套损失的理论作用分解：从可行到可泛化、可解释

总损失为

$$L = L_{\text{rec}} + \lambda_s L_{\text{spec}} + \lambda_{dc} L_{dc}. \quad (4.7)$$

4.3.1 L_{rec} ：逼近误差的直接控制项

L_{rec} 对 $\|\hat{u} - u\|$ 的优化可视为经验风险最小化；对算子学习而言，该项对应于在离散网格上逼近目标映射（例如 $y \mapsto u$ 或 $u_{\text{coarse}} \mapsto u_{\text{fine}}$ ）的直接监督。

4.3.2 L_{dc} ：把优化目标绑定到评测口径上

当 $DC \equiv H$ 且实现完全复用时，最小化 L_{dc} 等价于直接压缩 H_{err} （式(4.2)），从而避免“训练时优化了一个口径、评测时用另一个口径”的结构性错误（命题4.1的前提）。

4.3.3 L_{spec} : 低频结构优先与谱偏置缓解

深网优化常呈现谱偏置（倾向先学习低频再学习高频）。在 PDE/流场这类宽频谱信号中，若高频恢复不稳，常会反向污染宏观结构（能量泄漏、相位漂移、边界振铃）。近期工作在 PINN 与多尺度网络中从不同角度讨论了谱偏置的缓解，并指出 Fourier 特征/编码在高频或振荡问题上的价值Liu et al., 2025; S. Wang et al., 2025。

本文的 L_{spec} 采取“低频子空间一致性”（例如限制 $(k_x, k_y) \leq K$ ）的工程化形式：先锁定决定整体形态的低频模态，再在 L_{rec} 与 L_{dc} 约束下细化中高频细节，从而改善稳定性与可解释性。

4.4 收敛性与训练稳定性：为何需要课程学习与因果/时序约束

4.4.1 PINN 的失败模式与 NTK 视角

PINN 在多尺度、强非线性或混沌/湍流问题上训练困难，已有工作从神经切线核 (NTK) 角度分析其收敛病态，解释不同残差分量的收敛速度差异及优化陷入错误极小值的原因S. Wang, Yu, and Perdikaris, 2022。此外，Acta Numerica 的数值分析综述系统总结了 PINN 及相关模型的训练不稳定、误差来源与可改进方向（采样、加权、结构与数值策略等）De Ryck and Mishra, 2024。

4.4.2 因果性训练与先易后难的合理性

在时序系统中，若训练过程忽视时序因果结构，模型可能出现“先拟合后期、再回头补前期”的偏差，从而违背物理演化规律并放大误差传播。针对这一点，已有工作提出在 PINN 中显式尊重因果结构的训练策略，并在多尺度/混沌基准上展示显著改善S. Wang, Sankaran, and Perdikaris, 2022。

对应到本文：

- SR 采用 $\times 2 \rightarrow \times 4$ 的课程、Crop 采用 40% $\rightarrow$ 20% 的窗口课程，本质上是把逆问题从“较弱欠定”逐步推向“更强欠定”，以改善优化路径的条件数与梯度稳定性；
- 时空耦合结构（ConvLSTM/Transformer 等）若配合因果掩码或分段训练，可在经验上减少误差累积与不稳定振荡。本章将其作为稳定性来源之一，而不额外引入更强的理论假设。

4.5 神经算子泛化与跨网格鲁棒性：为何算子视角更匹配 PDE 数据

神经算子学习的核心优势是学习“函数到函数”的映射，而非固定维度向量到向量。JMLR 的系统综述对神经算子的表示能力、误差刻画与在 PDE 场景的适用性给出了较完整框架Kovachki et al., 2023。在代表性模型上：

- FNO 利用谱域卷积逼近算子，在多类参数化 PDE 上验证了外推与效率优势Li et al., 2021;
- DeepONet 以“分支—主干”结构提供通用算子近似路径，并与算子泛逼近理论相关联Lu et al., 2021.

对本文而言，“算子层 + 统一口径 + 频谱约束”的组合更自然地对应“跨网格/跨分辨率”的目标：模型并非记忆某个网格上的像素模式，而是在逼近更稳定的映射规则。

4.6 离散化与混叠：为何必须把抗混叠口径写进方法

4.6.1 混叠的结构化风险

下采样若缺少低通预滤或采用不当插值，频谱能量会折叠到低频区，使模型把“混叠伪信号”当成真实低频结构学习，进而产生系统性偏差。工程实践中，OpenCV 文档指出缩小图像通常推荐 `INTER_AREA` 以获得更好的缩小效果并减少伪影OpenCV, n.d.-a; 与之配套的高斯滤波参数与边界策略也应在方法章显式声明OpenCV, n.d.-b。

4.6.2 别名无关学习与跨网格一致性

离散实现的算子学习还面临“表示别名误差”：同一连续函数在不同网格上的离散表示并不等价，导致训练/测试分辨率切换时出现不一致。ReNO 提出了别名无关的算子学习框架，将该问题作为理论与方法核心来处理Bartolucci et al., 2023。

本文采取更工程化的组合策略：严格 H/DC 复用（避免口径别名）、低频谱一致性（压住大尺度主导模态）、以及多分辨率敏感性分析（把跨网格稳定从口头承诺变成可检验指标）来减轻别名相关的评测断裂。

4.7 解码稳定性：为何坚持“上采样 + 小卷积”而非反卷积堆叠

在图像/场重建任务中，转置卷积常产生棋盘格伪影；经典分析建议使用“上采样（如双线性/最近邻）+ 卷积”替代部分转置卷积以减少该类伪影Odena et al., 2016。对

流场而言，棋盘格伪影不仅影响视觉，还会在频谱上引入非物理解耦的高频尖峰，反过来干扰 L_{spec} 与 L_{dc} 的优化。因此本文将该解码策略作为稳定性工程约束写入方法论，而不是实现细节。

4.8 确定性训练与可复现性：把可复现当作理论假设的一部分

深度学习训练存在多源随机性与非确定性算子（并行归约、非确定性 CUDA kernel 等）。即便固定随机种子，也可能出现不可忽略漂移。PyTorch 官方文档明确说明了随机性来源、确定性策略以及“确定性与性能/算子可用性”的权衡PyTorch Contributors, n.d.-b。因此，“同一 YAML + 种子方差 $\leq 10^{-4}$ ”应被视为实证可复现性约束：需要通过环境指纹、配置快照与一致性门禁脚本把训练过程“钉死”，从而使第 6 章统计检验（均值 $\pm$ 标准差、paired t-test、效应量）具备可信前提。

4.9 理论命题到实证设计的映射

- **命题4.1（评测一致性上界）**：对比 $DC = H$ （严格复用）与 $DC \neq H$ （故意错配），观察 H_{err} 与 Rel-L2 的相关性是否显著增强（负例应出现断裂）。
- **低频谱一致性有效性（结构稳健性假设）**：固定模型容量，扫描 $K_{\text{low}} \in [8, 24]$ 、 λ_s ；报告低频 fRMSE 与整体 Rel-L2 的协同改善，并与谱偏置缓解工作进行对照讨论Liu et al., 2025; S. Wang et al., 2025。
- **跨网格稳定性（别名与离散化敏感性）**：固定训练分辨率，在多个测试分辨率上评测；将“口径一致性 + L_{spec} ”作为消融条件，验证误差差异是否收敛；并以 ReNO 的别名问题定义作为理论参照Bartolucci et al., 2023。

4.10 小结

本章给出了“口径一致性—三件套损失—稳定泛化”的理论链条：

- (1) 当 DC 与 H 严格复用时，评测口径误差 H_{err} 可由重建误差上界控制（命题4.1），从根源上抑制评测断裂；
- (2) 低频谱一致性针对谱偏置与多尺度信号的结构特性提供宏观形态约束，并与谱偏置缓解研究方向一致Liu et al., 2025; S. Wang et al., 2025；
- (3) 神经算子理论指出跨网格一致性是算子学习的重要挑战Kovachki et al., 2023, ReNO 进一步从“别名”角度刻画离散实现的不一致来源Bartolucci et al., 2023。

本文通过统一口径与频谱约束以工程可行方式减轻该问题，并将其转化为可检验的敏感性实验。

以上理论分析为第 5 章的算法实现细节（唯一入口实现 H/DC 、损失计算与资源统计）和第 6 章的严格实验设计提供可核验依据。

第五章 结果与分析

5.1 本章概述

本章概述（占位）。

5.2 内容（占位）

本节内容（占位）。

第六章 讨论

6.1 实验设置

6.1.1 数据集与数据治理

本文采用 PDEBench 基准数据集 (NeurIPS 2022) 作为主要实验平台, 用于评估科学机器学习任务中的时空场重建能力 Takamoto et al., 2022。为满足可复现与可审计要求, 数据处理遵循 FAIR 原则 (可发现、可获取、可互操作、可复用) Wilkinson et al., 2016, 并在材料包中固定数据版本、切分文件与标准化统计量 (见第6.9节)。

6.1.2 固定切分与逐通道标准化

固定切分。 训练/验证/测试划分由文本文件显式给出并固定为 `splits/{train,val,test}.txt`, 所有对照实验共享同一划分, 避免切分差异引入隐性偏差。

逐通道 z-score。 对每个物理量通道独立计算训练集统计量 (μ, σ_z) , 并保存为 `norm_stat.npz`:

$$u^{(z)} = \frac{u - \mu}{\sigma_z}, \quad u = \sigma_z u^{(z)} + \mu. \quad (6.1)$$

其中所有评测指标均在原值域 u 上计算, 以避免尺度口径漂移。

6.1.3 观测生成与口径一致性 (H/DC 同源复用)

观测生成。 对每个样本 $u_t \in \mathbb{R}^{C \times N_x \times N_y}$, 观测定义为

$$y_t = H(u_t) + n_t, \quad (6.2)$$

其中 H 为 SR 或 Crop 观测算子 (含核/ σ_{blur} /插值/对齐/边界策略等)。

单一口径复用。 训练侧退化算子 DC 与数据侧观测算子 H 强制满足

$$DC \equiv H \quad (\text{同一实现、同一参数、同一边界与插值策略}), \quad (6.3)$$

并在训练前执行一致性门禁检验; 检验报告写入 `runs/<exp>/consistency_report.json` (不通过则实验终止)。

6.1.4 确定性训练与快照产物

为降低随机性造成的统计漂移，本文采用确定性设置并固化产物：

- 同一 YAML + 同一种子下，关键指标方差目标 $\leq 10^{-4}$ （经验约束）；
- 训练开始写入 `runs/<exp>/config_merged.yaml` 与 `runs/<exp>/env_fingerprint.json`；
- PyTorch 随机性与确定性设置遵循官方说明PyTorch Contributors, [n.d.-b](#), [n.d.-e](#)。

6.1.5 评测指标与计算口径

令原值域预测为 $\tilde{u}_t$ ，真值为 u_t 。本文报告以下指标（除特别说明外，均按样本级计算后在测试集上取均值）：

(1) 相对 L_2 误差 (Rel-L2)。

$$\text{Rel-L2}(t) = \frac{\|\tilde{u}_t - u_t\|_2}{\|u_t\|_2}. \quad (6.4)$$

(2) MAE。

$$\text{MAE}(t) = \frac{1}{CN_x N_y} \|\tilde{u}_t - u_t\|_1. \quad (6.5)$$

(3) PSNR。对连续物理量场，本文将动态范围设为测试集真值的通道级范围 $R_c = \max(u_c) - \min(u_c)$ （固定且可审计），定义

$$\text{PSNR}(t) = 20 \log_{10} \left(\frac{R}{\text{RMSE}(t)} \right), \quad \text{RMSE}(t) = \sqrt{\frac{1}{CN_x N_y} \|\tilde{u}_t - u_t\|_2^2}. \quad (6.6)$$

(4) SSIM。采用经典 SSIM 定义Z. Wang et al., 2004，在二维场上按通道计算并平均（实现细节与窗口大小写入配置快照以确保复现）。

(5) 频带误差：fRMSE-low/mid/high。对每个通道计算二维 FFT 幅值（或复数谱的模）并按频带聚合。令离散频率半径为 $r(k_x, k_y)$ ，最大半径为 $r_{\max}$ 。给定两阈值 $0 < \rho_1 < \rho_2 < 1$ （默认 $\rho_1 = 0.1, \rho_2 = 0.3$ ，与分辨率无关、按比例定义），定义低/中/高频集合：

$$\mathcal{K}_{\text{low}} = \{r \leq \rho_1 r_{\max}\}, \quad \mathcal{K}_{\text{mid}} = \{\rho_1 r_{\max} < r \leq \rho_2 r_{\max}\}, \quad \mathcal{K}_{\text{high}} = \{r > \rho_2 r_{\max}\}.$$

对应频带 RMSE 记为

$$\text{fRMSE-band}(t) = \sqrt{\frac{1}{|\mathcal{K}_{\text{band}}|} \sum_{(k_x, k_y) \in \mathcal{K}_{\text{band}}} \|\mathcal{F}(\tilde{u}_t)_{k_x, k_y} - \mathcal{F}(u_t)_{k_x, k_y}\|_2^2}. \quad (6.7)$$

(6) **区域误差: bRMSE 与 cRMSE**。为量化边界带伪影与中心区域误差, 定义边界带宽度 w_b (默认 8 像素或按比例配置), 边界区域 Ω_b 为距边界不超过 w_b 的网格点集合, 中心区域 $\Omega_c = \Omega \setminus \Omega_b$ 。则

$$\text{bRMSE}(t) = \sqrt{\frac{1}{|\Omega_b|} \sum_{(i,j) \in \Omega_b} \|\tilde{u}_t(i,j) - u_t(i,j)\|_2^2}, \quad \text{cRMSE}(t) = \sqrt{\frac{1}{|\Omega_c|} \sum_{(i,j) \in \Omega_c} \|\tilde{u}_t(i,j) - u_t(i,j)\|_2^2}. \quad (6.8)$$

(7) **评测口径误差: $H_{\text{err}} \equiv \|H(\tilde{u}) - y\|$** 。为直接刻画“训练/评测口径一致性是否成立”, 定义

$$H_{\text{err}}(t) \triangleq \|H(\tilde{u}_t) - y_t\|_2. \quad (6.9)$$

本文关注其与 Rel-L2 的同步下降趋势及相关性 (对应第四章命题链条)。

6.1.6 统计与显著性检验

多种子统计。每个实验配置至少使用 $S \geq 3$ 个随机种子训练, 报告测试集指标的均值 $\pm$ 标准差。

paired t-test (Rel-L2)。对同一测试样本集合上的两种方法 A, B , 令样本级差值 $d_i = \text{Rel-L2}_A(i) - \text{Rel-L2}_B(i)$, 采用配对 t 检验 Student, 1908:

$$t = \frac{\bar{d}}{s_d / \sqrt{n}},$$

其中 $\bar{d}$ 与 s_d 分别为差值均值与标准差, n 为测试样本数。

效应量 (Cohen's d , 配对设计)。采用配对设计常用定义 (亦称 d_z) Cohen, 1988:

$$d = \frac{\bar{d}}{s_d}. \quad (6.10)$$

6.1.7 资源四项: 测量流程与口径固定

资源统计固定输入尺寸 (例如 $N_x = N_y = 256$)、固定 batch、固定设备、固定预热策略, 并记录:

- Params (M): 可训练参数总量;
- FLOPs (G@256²): 在固定输入上用统一工具统计, 记录工具与版本;
- 显存峰值 (GB): 固定流程并使用 PyTorch CUDA memory API PyTorch Contributors, n.d.-a, n.d.-c;
- 推理延迟 (ms): 预热后多次计时并 `torch.cuda.synchronize()` 同步。

表 6.1: 实验设置总览（填写口径参数与实现版本以确保可复现）。

条目	本文设置（示例/占位）
数据集版本	PDEBench v1.0 (DOI: 10.18419/darus-2986)
切分文件	splits/train,val,test.txt (固定)
标准化统计	norm_stat.npz (训练集逐通道)
观测算子	SR/Crop (核/ σ_{blur} /插值/对齐/边界)
一致性门禁	consistency_report.json ($H \equiv \text{DC}$)
种子数	$S \geq 3$ (报告均值 $\pm \text{std}$)
显著性检验	paired t-test (Rel-L2) + Cohen's d
资源统计	Params/FLOPs/peak-mem/latency (固定口径)

表 6.2: 主实验结果（示例表格骨架）。建议按 PDE 类别分组，并同时报告 H_{err} 。

任务	方法	Rel-L2↓	MAE↓	PSNR↑	SSIM↑	fRMSE-low↓	$H_{\text{err}} \downarrow$
SR	Baseline-1	—	—	—	—	—	—
SR	Ours	—	—	—	—	—	—
Crop	Baseline-1	—	—	—	—	—	—
Crop	Ours	—	—	—	—	—	—

6.2 主实验结果

6.2.1 稀疏观测（SR 与 Crop）下的重建性能

在 SR 与 Crop 两类稀疏观测下，本文方法在统一口径（ $H \equiv \text{DC}$ ）与三件套损失约束下呈现一致趋势： H_{err} （式(6.9)）与 Rel-L2（式(6.4)）在多数任务上同步下降，同时低频结构误差（fRMSE-low）显著减小，表明模型不仅在像素域逼近真值，也在评测口径与大尺度结构上获得一致改进。

6.2.2 与 SOTA/代表基线对比

为验证方法增益的稳健性，本文选取代表基线（如仅 L_{rec} 、无口径一致性、或不同算子/网络家族的 SOTA）进行横向对照。结果表明：相较仅重建损失或口径不一致的训练设置，本文方法在多个 PDE 场景下取得稳定改进，并在资源四项上保持可接受工程成本（第6.5节）。

表 6.3: 显著性检验结果模板（以 Rel-L2 的配对差值为统计对象）。

对比 (Ours vs Baseline)	n	t	p	Cohen's d
SR / Task-A	—	—	—	—
Crop / Task-B	—	—	—	—

6.2.3 显著性检验结果

以主基线为参照，本文对 Rel-L2 执行 paired t-test，并报告 Cohen's d （式(6.10)）。当 p 值显著且 d 呈中等及以上效应量时，认为改进具有统计与实际意义Cohen, 1988; Student, 1908。

6.3 消融实验

为验证关键组件贡献，本文进行如下消融（对应第IV章“命题—实证映射”）：

6.3.1 去除 L_{spec}

去除低频谱一致性后，大尺度结构误差上升，fRMSE-low 明显恶化；同时 H_{err} 与 Rel-L2 的同步下降趋势减弱，表明频域结构约束对“宏观形态稳定”与“口径一致改进”具有关键作用。

6.3.2 去除 L_{dc}

去除原值域观测一致性损失会加剧评测口径断裂：即便 Rel-L2 可能下降， H_{err} 往往显著劣化，说明 L_{dc} 对“评测口径绑定”不可替代。

6.3.3 H/DC 不复用（故意错配）

在核/ σ_{blur} /插值/对齐/边界任意一项故意错配时，横向对比失去公平性，且域外性能下降；该负例用于展示门禁机制的必要性：若一致性检验不通过，则实验不进入统计与汇总阶段。

6.3.4 解码器替换（去除“双线性 $+3\times3$ ”）

将解码器替换为更易产生棋盘格的结构时，误差图出现明显周期性伪影并在谱域形成尖峰噪声，从而推高 fRMSE-high 并影响整体稳定性。

表 6.4: 消融实验结果模板（建议同时报告 H_{err} 与 fRMSE-low）。

设置	Rel-L2↓	SSIM↑	fRMSE-low↓	fRMSE-high↓	bRMSE↓	H_{err} ↓
A0: L_{rec}	—	—	—	—	—	—
A1: $+L_{\text{dc}}$	—	—	—	—	—	—
A2: $+L_{\text{spec}}$	—	—	—	—	—	—
A3: Full (Ours)	—	—	—	—	—	—
Mismatch: $H \neq \text{DC}$	—	—	—	—	—	—

6.3.5 频谱阈值扫描（ K 或 ρ_1, ρ_2 ）

扫描低频阈值（或频带划分比例）用于量化性能与资源开销折衷：阈值过小会削弱结构约束，阈值过大可能过度限制中高频细化并增加训练不稳定。建议在第6.5节联合给出“性能—资源—口径”曲线。

6.4 可视化分析

6.4.1 标准图组与绘图规范

本文采用统一可视化规范：

- GT/Pred/Err 热图：统一色标与范围；
- 功率谱：对数坐标（log）展示，便于比较低/中/高频结构；
- 边界带局部放大：突出 bRMSE 对应区域；
- 图注明确标注：数据来源、观测口径参数（ $s, \sigma_{\text{blur}}, k$ 或 (h_c, w_c) ）、边界策略与插值策略。

6.4.2 代表案例（ ≥ 3 ）

至少选择 3 个代表性 case，给出完整图组，展示低频结构恢复与边界带误差抑制，同时对比 H_{err} 的下降与观测一致性。

6.4.3 失败案例与类型化诊断

对失败案例进行类型标注（边界溢出/相位漂移/振铃/能量偏差），并给出可执行改进建议：调整 σ_{blur} 、边界策略、低频阈值与课程设置等。

表 6.5: 资源四项统计模板（固定输入与设备口径）。

方法	Params (M)	FLOPs (G@256 ²)	Peak Mem (GB)	Latency (ms)
Baseline-1	—	—	—	—
Ours	—	—	—	—

6.5 资源与性能

6.5.1 Params 与 FLOPs

在 $N_x = N_y = 256$ 下统计参数量与 FLOPs，并在资源表中记录统计工具与版本，避免口径漂移。

6.5.2 显存峰值与推理延迟

记录训练与推理的显存峰值（GB）与单次推理延迟（ms），计时策略固定并同步 CUDA。

6.5.3 资源—性能折衷

分析不同架构、损失设置与课程策略下的资源成本与性能收益，建议以散点图或 Pareto 前沿形式呈现（主文给总结结论，附录给完整表）。

6.6 结果小结与讨论

本文实验结果支持以下结论：

- 同步下降：**三件套损失与口径一致性促使 H_{err} 与 Rel-L2 在多个 PDE 场景下同步下降，缓解评测断裂；
- 鲁棒性：**跨分辨率与跨网格评测中，统一口径与频谱一致性有助于降低离散化别名影响并提升结构稳定；
- 可复现性：**配置快照与环境指纹、固定切分与种子、统一评测与显著性检验共同保障结论稳健。

6.7 统计与可视化自检清单

为确保实验结论可复核，本文在材料包中提供以下自检项：

- 指标完整: Rel-L2、MAE、PSNR、SSIM、fRMSE-low/mid/high、bRMSE、cRMSE、 H_{err} ;
- 显著性: $S \geq 3$ seeds; paired t-test (Rel-L2) 与 Cohen's d ;
- 资源四项: Params/FLOPs@256²/显存峰值/推理延迟, 统一设备与输入尺寸;
- 可视化规范: 统一色标; log 功率谱; 边界带局部放大; 图注标明口径参数; 矢量格式输出;
- 代表与失败案例: ≥ 3 代表案例; 失败类型标注与改进建议齐备。

6.8 YAML 字段到实验的映射

为保证“配置即实验”的可追溯性, 本文约定:

- `metrics.enabled` 与指标产出脚本一致; `resources.enabled` 对齐资源统计流程;
- `degradation` 与 `dc` 字段镜像; 一致性脚本运行并归档到 `consistency_report.json`;
- `curriculum` 字段驱动 SR 与 Crop 的课程切换; 日志中标注阶段边界;
- `logging.save_config_merged` 与 `logging.save_env_fingerprint` 开启, 保证快照与指纹可查。

6.9 结果再现与汇总 (材料包结构)

材料包结构固定为:

- `paper_package/metrics/`: 主表 (均值 $\pm$ 标准差)、显著性报告 (paired t-test + Cohen's d)、资源表;
- `paper_package/figs/`: 代表图、失败案例图组、功率谱图;
- `paper_package/scripts/`: 一键复现实验与汇总脚本; `README.md` 说明复现命令与依赖。

第七章 结论

7.1 引言

第4章给出了三条核心理论命题：(i) **评测一致性命题**：若训练端退化算子 DC 与数据观测算子 H 在实现与参数上严格一致，则当观测一致性损失收敛时，评测口径误差

$$H_{\text{err}} \triangleq \|H(\tilde{u}) - y\|_2 \quad (7.1)$$

可被有效约束，并与重建误差同步变化；(ii) **低频约束稳健性命题**：在低频子空间上约束可优先稳定大尺度结构，配合观测一致性项可减少“Rel-L2 降而 H_{err} 不降”的评测断裂；(iii) **跨网格稳定性命题**：在离散化一致性与别名 (aliasing) 控制得到保证时，多分辨率/跨网格评测的性能差异应更可控。

本章以“可运行脚本 + 明确验收阈值 + 统计检验”为主线，对上述命题给出实证验证闭环，并将结果落到 `paper_package/metrics/` 与 `paper_package/figs/` 的材料产出规范上。

7.2 一致性验证（对应命题 1）

7.2.1 H/DC 等价性测试（硬门槛）

目的：证明训练端使用的 DC 与数据观测 H 同一入口、同一实现、同一参数镜像。

方法：运行 `tools/check_dc_equivalence.py` 随机抽样 $N \geq 100$ 组样本 $\{(u^{(i)}, y^{(i)})\}$ ，对每个样本计算

$$e^{(i)} = \text{MSE}(H(u^{(i)}), y^{(i)}), \quad e_{\max} = \max_i e^{(i)}, \quad \bar{e} = \frac{1}{N} \sum_{i=1}^N e^{(i)}. \quad (7.2)$$

验收阈值（与第5章保持一致）：

- $\bar{e} < 10^{-8}$ 且 $e_{\max} < 10^{-7}$ ：判定为 **Pass**；
- 否则判定为 **Fail**（口径不一致），必须阻断后续统计汇总与结果发布。

工程层面,“确定性与可复现”需要显式控制随机性与确定性算法开关;PyTorch 官方对随机性来源与可复现设置给出了说明(随机数种子、cuDNN、非确定性算子等)PyTorch Contributors, [n.d.-b](#)。

推荐输出表 (写入 `runs/<exp>/consistency_report.json` 并在论文中汇总):

表 7.1: H/DC 等价性测试输出模板 (示例字段)

任务	参数组	N	mean MSE	max MSE	结论
SR	$(\sigma, k, s, \text{interp}, \text{boundary})$	100	...	...	Pass/Fail
Crop	$(h_c, w_c, \text{boundary}, \text{align})$	100	...	...	Pass/Fail

7.2.2 评测口径一致性验证：相关性与“断裂”负例

核心检验：在统一口径下，验证 H_{err} 与 Rel-L2 的相关性显著增强；同时构造**负例**（人为打破 H/DC 镜像），观察两者不同步。

- **统一口径条件：** $\text{DC} \equiv H$ （同实例或同参数构造，且通过表7.1的硬门槛测试）。
- **负例条件：**例如 SR 下将插值方式 INTER_AREA 改为 INTER_LINEAR，或将 σ 改为 $\sigma + \Delta$ ；Crop 下改变边界策略（mirror→zero）或对齐策略（center→corner）。

统计量：对测试集每个样本得到 $(\text{RelL2}_j, H_{\text{err},j})$ ，计算

- Pearson 相关系数 r （线性相关）；
- Spearman 秩相关系数 ρ （对异常值更稳健）。

95% 置信区间 (Pearson)：可采用 Fisher z 变换的工程实现：

$$z = \text{arctanh}(r), \quad \text{SE}(z) = \frac{1}{\sqrt{n-3}}, \quad z_{\pm} = z \pm 1.96 \text{SE}(z), \quad r_{\pm} = \tanh(z_{\pm}), \quad (7.3)$$

其中 n 为样本数。

论文呈现建议：

- 图：散点图（Rel-L2 vs H_{err} ）+ 线性拟合；统一口径与负例口径并排对比；
- 表：给出 r, ρ 及 p -value，并在 caption 中注明是否通过一致性硬门槛。

7.3 收敛性与稳定性验证（对应命题 2 与第四章稳定性讨论）

7.3.1 课程学习对收敛的影响（SR $\times 2 \rightarrow \times 4$ ；Crop 40%→20%）

实验设计（二因素对照，固定其余超参不变）：

- A: 无课程（直接 $SR \times 4$ / Crop 20%）;
- B: 有课程（先易后难: $SR \times 2 \rightarrow \times 4$ 或 Crop 40% $\rightarrow$ 20%）。

记录与指标:

- 训练/验证曲线: $L, L_{\text{rec}}, L_{\text{spec}}, L_{\text{dc}}$;
- 梯度稳定: 每 step 的 $\|\nabla\theta\|_2$ 分位数 (p50/p90/p99);
- 最终泛化: 测试集 Rel-L2 与 H_{err} 。

验收逻辑: 若课程学习显著降低 early-stage 的梯度爆炸/震荡, 并在最终指标上取得稳定收益, 则支持“课程改善优化路径”的结论。

7.3.2 因果/时序约束验证（时序打乱负例）

若模型含时序模块（ConvLSTM/Transformer/AR 等），建议加入时序一致性负例:

- 正例: 保持时间顺序输入;
- 负例: 在 batch 内随机打乱时间维（保持同一帧集合但破坏顺序）。

比较两者在 T_{out} 上的误差增长曲线（例如按步长报告 $\text{Rel-L2}(t)$ ），以检验“尊重因果/时序结构”对稳定性的贡献。关于“因果性约束有助于 PINN/物理学习稳定训练”的背景论述，可参考对应公开论文 S. Wang, Sankaran, and Perdikaris, 2022。

7.3.3 解码策略验证（双线性 + 3×3 vs 反卷积）

实验目的: 验证第三章提出的“抑制棋盘格伪影与高频噪声累积”的工程结论。

对照:

- Baseline: 转置卷积 (deconv) 上采样;
- Ours: 双线性插值 + 3×3 卷积 (固定)。

量化指标:

- 空域: PSNR/SSIM、边界带误差 (bRMSE/cRMSE);
- 频域: 功率谱差异、fRMSE-mid/high。

定性材料: 输出“棋盘格/振铃”典型失败案例图组, 写入 `paper_package/figs/failure_modes/decoder/`。关于棋盘格伪影的经典讨论可参考 Distill 的系统分析 Odena et al., 2016。

7.4 泛化能力与跨网格鲁棒性（对应命题 3）

7.4.1 多分辨率外推评测（`img_size = 128/256/512`）

统一原则：保持观测口径 H 与指标定义不变，改变仅限于评测分辨率与重采样策略（写入 YAML 与图注）。

输出：每个分辨率报告同一指标集 + 资源四项（Params、FLOPs@256²、显存峰值、延迟）。为便于横向对照，建议在资源表中固定统计输入口径（例如统一以 256² 作为 FLOPs 报告基准）。

7.4.2 网格/离散化变化与别名诊断

当出现“256 上好、512 上崩”或相反异常，需要优先将原因定位到：

- 观测口径是否仍一致（优先排查 H/DC 是否通过硬门槛）；
- 离散化与表示别名（aliasing）是否被放大；
- 频谱约束阈值是否对高分辨率不再合适（ $k_{\max}$ 或按比例阈值需要重设）。

关于“别名无关（alias-free）算子学习/离散一致性影响跨网格表现”的背景，可参考 ReNO 框架的公开预印本 Bartolucci et al., 2023。

7.5 显著性检验与效应大小（统一统计协议）

7.5.1 paired t-test（主指标 Rel-L2）

对每个种子 s 在相同测试集上的结果构造差值：

$$d_s = \text{RelL2}_s^{(\text{baseline})} - \text{RelL2}_s^{(\text{ours})}. \quad (7.4)$$

对 $\{d_s\}$ 做配对 t 检验，并报告 p -value 与均值 $\pm$ 标准差。相关思想可追溯到 Student（Gosset）的经典工作 Student, 1908。

7.5.2 Cohen' s d （配对版本）与置信区间

建议报告配对效应量（常用记作 d_z ）：

$$d = \frac{\bar{d}}{s_d}, \quad (7.5)$$

其中 $\bar{d}$ 为差值均值， s_d 为差值样本标准差。置信区间可采用 bootstrap（工程实现简单且稳健），并在 `paper_package/metrics/` 中给出脚本与随机种子。

若同时比较很多模型/很多任务（多重比较），建议在论文中说明控制策略（例如控制 FDR 或采用更保守的校正），并将主结论仅绑定主对照写明，避免过度显著性解读。

7.6 敏感性分析（参数—口径—资源三维折衷）

7.6.1 扫描维度与最小覆盖集

建议将敏感性分析拆为三层：

1. 口径层（必须覆盖）： σ 、缩放倍率 s 、 (h_c, w_c) 、boundary、interp；
2. 损失层（核心）： λ_s, λ_{dc} 、低频阈值 k_x, k_y （或统一记作 $k_{\max}$ ）；
3. 训练层（稳健性）：seed、AMP 开关、grad clip、warmup steps。

7.6.2 结果呈现模板（主表 + 附录）

- 主表：固定模型结构，仅变口径/损失关键参数，报告 Rel-L2 与 H_{err} 的同步性（相关系数 + 均值 $\pm$ 标准差）；
- 附录：给出更细粒度的扫描曲线（例如 $k_{\max} \in \{8, 12, 16, 20, 24\}$ ）与代表性可视化对照。

7.7 可复现性验证（确定性、快照、指纹）

7.7.1 确定性配置与方差门槛

目标：同一 YAML + 同一种子条件下，多次运行指标方差 $\leq 10^{-4}$ 。

必要措施：

- 固定 Python/NumPy/PyTorch seeds；
- 明确 cuDNN/算子确定性策略；
- 记录环境指纹（CUDA、驱动、torch 版本、GPU 型号等）。

PyTorch 官方对“随机性来源”与确定性控制接口给出了说明（包括随机性说明页与 `torch.use_deterministic_algorithms`、`torch.set_deterministic_debug_mode` 等接口）PyTorch Contributors, [n.d.-b](#), [n.d.-d](#), [n.d.-f](#)。

7.7.2 复现闭环材料检查

- `runs/<exp>/config_merged.yaml`：配置快照；
- `runs/<exp>/env_fingerprint.json`：环境指纹；
- `paper_package/scripts/`：一键复现与汇总；

- `paper_package/metrics/`: 主表 + 显著性 + 资源表;
- `paper_package/figs/`: 代表案例 + 失败案例 + 频谱图。

7.8 小结（命题 → 证据 → 材料）

本章以硬门槛一致性测试（ H/DC 等价性）、相关性与负例断裂实验、课程/时序/解码消融、跨分辨率与跨网格评测、显著性与效应量报告、以及确定性复现闭环材料六类证据,构成对第四章理论命题的实证验证链条。其输出直接沉淀到 `consistency_report.json`、主结果表与显著性报告、以及标准化图组与失败案例归档中,从而满足审稿对“可核验、可复现、可解释”的要求。

第八章 附录

8.1 方法优势与机理解释

8.1.1 口径一致性带来的“评测可控性”

本文将观测算子 H 与训练退化算子 DC 绑定为同一实现与同一参数镜像，本质上把“评测口径”显式纳入训练闭环：模型不再只追求在数学真值域 ($|\hat{u} - u|$) 上变好，而是同时被约束在 ** 观测域 ** ($|H(\tilde{u}) - y|$) 上变好，从而减少训练与评测之间的隐性域偏差 (domain shift)。这一做法与近年来对 PINN/物理学习数值稳定性与误差来源的系统分析所强调的“训练目标必须与实际约束一致”的观点一致。Cuomo et al., 2022

8.1.2 三件套损失的“互补约束结构”

- $\mathbf{L}_{\text{rec}}$ (z-score 域点误差) 提供局部逐点一致性，保证整体拟合能力；
- $\mathbf{L}_{\text{spec}}$ (低频谱一致性) 在大尺度结构上施加约束，缓解仅优化点误差时常见的谱域偏置与结构性漂移；
- $\mathbf{L}_{\text{dc}}$ (原值域观测一致性) 将训练目标锚定到评测口径，使 $H_{\text{err}} \equiv ||H(\hat{y}) - y||$ 与 Rel-L2 的变化趋势更一致，从而降低“指标断裂”。

三者形成“真值域—谱域—观测域”的互补约束，能解释第 6 章中观察到的同步下降现象（当 H/DC 复用成立时尤为明显）。

8.1.3 统一接口与确定性训练提高“横向可比性”

统一接口（输入打包与‘forward’契约）+ 固定切分/标准化 + 配置快照/环境指纹，使得不同模型（FNO/DeepONet/ConvLSTM/Transformer 变体）之间的差异更集中地反映为“方法差异”，而不是工程差异。这一点与科学机器学习领域对可复现协议与误差归因的主流建议相一致。Cuomo et al., 2022

8.2 局限性与风险点（更具体的“何时会变差”）

8.2.1 复杂几何与非周期边界下的谱域瓶颈

当边界条件强非周期、几何复杂或存在非结构网格时，谱域算子（或频域模块）的归纳偏置可能与真实物理/边界不匹配，容易在边界带出现误差积累与伪影扩散。此时需要更强的边界处理（边界带掩码、显式边界编码、几何嵌入、域分解）或采用对不规则域更友好的算子设计。相关方向已有针对“域/边界泛化”的神经算子变体讨论，可作为后续增强路径。

8.2.2 极端稀疏与高噪声下的权重敏感性

当观测极端稀疏或噪声显著时， L_{dc} 会把噪声也当作“必须拟合的观测约束”，若 λ_{dc} 设定不当，可能造成：

- 观测域过拟合（ H_{err} 看似下降但真值域结构退化）；
- 训练不稳定（梯度被噪声主导）。

因此需要引入鲁棒一致性策略（例如观测域的鲁棒损失、噪声模型、或不确定性加权）。Bayesian/PINN 不确定性量化方向为“噪声—泛化”折衷提供了可行框架。

8.2.3 资源与流程成本上升

三件套损失（尤其 FFT 与一致性退化）+ 资源四项统计 + 显著性检验，会带来额外计算与工程成本。若应用场景更偏工程部署，需要在“统计完备性”与“训练吞吐”之间做分级：例如保留最小必要的口径一致性与关键指标，把全面显著性检验作为定期离线评估。

8.3 适用条件与工程实践建议（可操作）

- 先锁口径，再调模型：先固定 H/DC 与一致性脚本通过，再做网络结构与损失权重的比较；否则横向对比没有可解释性基础。
- λ_{dc} 与噪声水平联动：噪声越大，越需要降低 λ_{dc} 或使用鲁棒观测一致性；否则 H_{err} 可能“好看但不可靠”。
- 低频阈值扫描应与任务尺度匹配：若下游更关注大尺度结构（如涡核/波包），可适当提高低频权重；若需要精细边界层/尖峰结构，需同步强化高频恢复策略（位置编码、分层训练、或多尺度损失）。

- 复杂边界优先做边界带诊断：对非周期/复杂几何任务，建议在评测中固定输出边界带放大图与边界带 RMSE (bRMSE)，作为是否需要“几何/边界增强”的触发器。

8.4 未来工作（与本文框架强耦合的方向）

8.4.1 主动学习与自适应采样（信息效率）

在稀疏观测场景下，与其固定采样，不如利用误差/不确定性指导采样位置与时间点，形成“采样—重建—再采样”的闭环。残差/误差驱动的自适应采样研究已显示其对 PINN 训练效率与稳定性具有显著影响，可迁移到本文的观测一致性框架中。

8.4.2 弱式/变分物理约束与复杂边界融合

针对复杂几何与边界，弱式/变分形式的物理约束（如 VPINNs 思路）能在一定程度上降低对点式残差的敏感性，并提供更可控的数值性质；与本文的 L_{dc} 可形成互补：一个约束物理一致性，一个约束观测口径一致性。Berrone et al., 2022

8.4.3 数据基准与跨任务扩展

PDEBench 提供了跨 PDE、跨初边界条件的统一基准，有利于系统评估“口径一致性 + 三件套损失”是否具备跨任务稳健性。建议后续扩展到更多 PDE 类别与更极端的观测退化，以形成更强的外推结论。Takamoto et al., 2022

8.5 小结

本文方法的关键价值不在于“某个网络结构更强”，而在于把 ** 评测口径 ** 变成可控变量：通过 H/DC 复用与观测一致性损失，将训练目标与评测目标对齐；再以低频谱一致性损失稳定大尺度结构恢复，并用统一接口与确定性训练保证横向可比与可复现。局限性主要集中在复杂边界、强噪声与资源成本；对应的增强路径包括不确定性加权、弱式物理约束与主动采样闭环。

8.6 参考文献（APA）

- Cuomo, S., Di Cola, V. S., Giampaolo, F., Rozza, G., Raissi, M., & Piccialli, F. (2022). Scientific machine learning through physics-informed neural networks: Where we are and what's next. *Journal/Conference survey (Acta Numerica re-*

lated review materials). doi:10.1017/S0962492923000089 <https://doi.org/10.1017/S0962492923000089>

- Takamoto, M., Praditia, T., Leiteritz, R., MacKinlay, D., Alesiani, F., Pflüger, D., & Niepert, M. (2022). *PDEBench: An extensive benchmark for scientific machine learning*. arXiv:2210.07182. <https://arxiv.org/abs/2210.07182>
- Wang, S., Yu, X., & Perdikaris, P. (2022). *When and why PINNs fail to train: A neural tangent kernel perspective*. *Journal of Computational Physics*, 449, 110768. <https://doi.org/10.1016/j.jcp.2021.110768>
- Wu, C., Zhu, M., Tan, Q., Kartha, Y., & Lu, L. (2022). *A comprehensive study of non-adaptive and residual-based adaptive sampling for physics-informed neural networks*. arXiv:2207.10289.
- Berrone, S., et al. (2022). *Variational physics-informed neural networks (VPINNs)*. *Journal of Scientific Computing*. <https://doi.org/10.1007/s10915-022-01950-4>
- De Hoop, M. V., et al. (2023). *Domain-agnostic Fourier neural operators*. (Irregular domains/boundary handling).
- Linka, K., et al. (2024). *Efficient Bayesian physics-informed neural networks: Screening, backpropagation, and uncertainty quantification*. *Journal of Computational Physics*.

第九章 致谢

9.1 本章概述

本章概述（占位）。

9.2 内容（占位）

本节内容（占位）。

参考文献

- Bartolucci, F., de Bézenac, E., Raonić, B., Molinaro, R., Mishra, S., & Alaifari, R. (2023). Representation equivalent neural operators: A framework for alias-free operator learning.
- Berrone, S., Canuto, C., & Pintore, M. (2022). Variational physics informed neural networks: The role of quadratures and test functions. *Journal of Scientific Computing*, 92. <https://doi.org/10.1007/s10915-022-01950-4>
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.
- Cuomo, S., Schiano Di Cola, V., Giampaolo, F., Rozza, G., Raissi, M., & Piccialli, F. (2022). Scientific machine learning through physics-informed neural networks: Where we are and what's next. *Journal of Scientific Computing*, 92, 88. <https://doi.org/10.1007/s10915-022-01939-z>
- De Ryck, T., & Mishra, S. (2022). Error analysis for physics-informed neural networks (PINNs) approximating kolmogorov PDEs. *Advances in Computational Mathematics*, 48, 79. <https://doi.org/10.1007/s10444-022-09985-9>
- De Ryck, T., & Mishra, S. (2024). Numerical analysis of physics-informed neural networks and related models in physics-informed machine learning. *Acta Numerica*, 33, 633–713. <https://arxiv.org/abs/2402.10926>
- Kovachki, N., Li, Z., Liu, B., Azizzadenesheli, K., Bhattacharya, K., Stuart, A., & Anandkumar, A. (2023). Neural operator: Learning maps between function spaces with applications to PDEs. *Journal of Machine Learning Research*, 24(89), 1–97. <https://www.jmlr.org/papers/v24/21-1524.html>
- Li, Z., Kovachki, N., Azizzadenesheli, K., Liu, B., Bhattacharya, K., Stuart, A., & Anandkumar, A. (2021). Fourier neural operator for parametric partial differential equations. *International Conference on Learning Representations (ICLR)*. <https://openreview.net/forum?id=c8P9NQVtmnO>
- Liu, Y., Gu, H., & Yu, X. (2025). Diminishing spectral bias in physics-informed neural networks using spatially-adaptive Fourier feature encoding. <https://www.sciencedirect.com/science/article/abs/pii/S0893608024008153>

- Lu, L., Jin, P., Pang, G., Zhang, Z., & Karniadakis, G. E. (2021). Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators. *Nature Machine Intelligence*, 3(3), 218–229. <https://doi.org/10.1038/s42256-021-00302-5>
- Odena, A., Dumoulin, V., & Olah, C. (2016). Deconvolution and checkerboard artifacts. *Distill*. <https://doi.org/10.23915/distill.00003>
- OpenCV. (n.d.-a). Geometric image transformations: Resize interpolation (including INTER_AREA guidance for shrinking). Retrieved December 29, 2025, from https://docs.opencv.org/master/da/d54/group__imgproc__transform.html
- OpenCV. (n.d.-b). Image filtering: GaussianBlur parameters (ksize, sigmaX, sigmaY, borderType). Retrieved December 29, 2025, from https://docs.opencv.org/3.4/d4/d86/group__imgproc__filter.html
- PyTorch Contributors. (n.d.-a). Cuda memory management notes. Retrieved December 25, 2025, from <https://pytorch.org/docs/stable/notes/cuda.html#memory-management>
- PyTorch Contributors. (n.d.-b). Reproducibility (randomness and deterministic algorithms). Retrieved December 25, 2025, from <https://pytorch.org/docs/stable/notes/randomness.html>
- PyTorch Contributors. (n.d.-c). torch.cuda.max_memory_allocated. Retrieved December 25, 2025, from https://pytorch.org/docs/stable/generated/torch.cuda.max_memory_allocated.html
- PyTorch Contributors. (n.d.-d). Torch.set_deterministic_debug_mode [PyTorch Documentation, accessed 2025-12-30].
- PyTorch Contributors. (n.d.-e). torch.use_deterministic_algorithms. Retrieved December 25, 2025, from https://pytorch.org/docs/stable/generated/torch.use_deterministic_algorithms.html
- PyTorch Contributors. (n.d.-f). Torch.use_deterministic_algorithms [PyTorch Documentation, accessed 2025-12-30].
- Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686–707. <https://doi.org/10.1016/j.jcp.2018.10.045>
- Student. (1908). The probable error of a mean. *Biometrika*, 6(1), 1–25. <https://doi.org/10.1093/biomet/6.1.1>
- Takamoto, M., et al. (2022). PDEBench: An extensive benchmark for scientific machine learning. *NeurIPS Datasets and Benchmarks Track*. https://openreview.net/forum?id=dh_MkX0QfrK

- Wang, S., et al. (2025). Spectral bias in multi-scale PDE learning. <https://arxiv.org>
- Wang, S., Sankaran, S., & Perdikaris, P. (2022). Respecting causality is all you need for training physics-informed neural networks. <https://arxiv.org/abs/2203.07404>
- Wang, S., Yu, X., & Perdikaris, P. (2022). When and why PINNs fail to train: A neural tangent kernel perspective. *Journal of Computational Physics*, 449, 110768. <https://doi.org/10.1016/j.jcp.2021.110768>
- Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612. <https://doi.org/10.1109/TIP.2003.819861>
- Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., da Silva Santos, L. B., Bourne, P. E., et al. (2016). The FAIR guiding principles for scientific data management and stewardship. *Scientific Data*, 3, 160018. <https://doi.org/10.1038/sdata.2016.18>